

Applied Econometric Policy Evaluation

Noter af Casper Moes (forår 2025)

Indholdsfortegnelse

Lineær regression og CEF (Cond. Exp. Func)	3
CEF-dekomposition.....	3
CEF's Prædiktions egenskab (Prediction Property)	4
Potential outcomes framework.....	4
Multiple lineær regression	5
Modellen.....	5
Motivation	6
MLR-estimatoren (moment-estimation)	6
Fortolkning af parametre	7
Frisch-Waugh Teoremet (for $k = 2$)	8
Mekaniske egenskaber ved OLS	8
Middelret (MLR.1-MLR.4).....	9
Varians (MLR.1-MLR.5).....	9
Bevis OLS-estimatorens varians (under MLR.1 – MLR.5)	10
Varians: β_j under MLR. 1 – MLR. 5	10
Statistiske tests.....	10
t-test	11
Følgende opfylder CLM – antagelserne.....	11
Varians: Fejlledet	11
Standardafvigelse: β_j	12
Standardfejl: β_j	12
(CLT-fortolkningen).....	12
F-tests	12
F-teststatistikken under CLM-antagelser	12
Idéen bag test af flere variable (intuition).....	13
Hypoteser	13
Testning mod et énsidet alternativ	13
Heteroskedasticitet	14
IV estimation.....	14
Gyldigt instrument.....	15


IV estimatoren	15
IV er konsistent (simpel regression)	15
OLS estimation versus IV estimation	17
IV estimation med $I < k$ endogene variable	17
Eksakt identifikation (IV-estimator).....	17
Overidentifikation (2SLS - estimator)	18
Generelle antagelser for IV estimation (matrix notation)	19
Tidsrækker	20
Tidsrækker III - Forelæsningsplan.....	20
OLS estimatoren (Recap)	20
OLS estimatoren for tidsrækker	21
Bevis: Simpel OLS er konsistent.....	21
Gentagende tværsnit.....	22
Uafhængige gentagende tværsobservationer.....	22
Difference in difference.....	23
Paneldata.....	23
Hvorfor er paneldata smart?	24
First difference estimator (antagelser).....	24
Denne er middelfret og konsistente under følgende antagelser	24
FD-estimator konsistens (med T tidsperioder).....	26

Lineær regression og CEF (Cond. Exp. Func).

Følgende er fra bogen **mostly harmless econometrics** af Angrist og Pischke. Det er en lækker beskrivelse af lineær regression som en procedure der (forsøger) at bestemme / estimerer CEF funktionen:

$$m(X) = E[y|X] \quad (CEF)$$

Som er illustreret herunder ved en sort linje:



CEF-dekomposition

Vi definerer blot en stokastisk variabel som bestående af to dele (Y er den stokastiske variabel vi dekomponerer):

$$Y = E[Y|X] + \epsilon \quad (Decomp)$$

, hvor $\epsilon = Y - E[Y|X]$.

Hvis vi kender CEF kan vi sige noget interessant om "fejlleddet" eller "restleddet". Nemlig at enhver funktion af X (som fx kan indeholde man x'ere) er ukorreleret med ϵ . Altså

$$\text{cov}(\epsilon, f(X)) = 0 \quad (Decomp. Property)$$

Bevis: Tag den betingede middelværdi til ϵ betinget på X:

$$\begin{aligned} E[\epsilon|X] &= E[Y - E[Y|X]] \\ &= E[Y|X] - E[E[Y|X]] \\ &= E[Y|X] - E[Y|X] = 0 \end{aligned}$$

Altså er hele det systematiske forhold mellem X og Y opfanget i CEF. Resten er "stokastisk" eller i regressionsanalyse blot ukorreleret med X'erne: De forklarende variable.

CEF's Prædiktions egenskab (Prediction Property)

Lad $m(X)$ være en funktion af X . CEF løser følgende problem

$$E[Y|X] = \arg \min_{m(X)} E[(Y - m(X))^2]$$

Altså er CEF den funktion som minimerer de kvadrerede afstande til Y . Dette er lowkey fuldstændig nøgle til at bruge OLS som forsøg på at predikterer Y . Vi finder noget der minder om CEF, og det fejleddet vil være ukorreleret med X 'erne. Altså viser X 'erne den kausale forklaring for Y 's opståen.

Bevis: Vi omskriver først indmaden af overstående postulat:

$$\begin{aligned}(Y - m(X))^2 &= (Y - E[Y|X] + (E[Y|X] - m(X)))^2 \\&= (Y - E[Y|X])^2 \\&\quad + 2(Y - E[Y|X])(E[Y|X] - m(X)) \\&\quad + (E[Y|X] - m(X))^2\end{aligned}$$

Vi ser ret hurtigt at første led er ligegyldigt idet $m(X)$ ikke indgår og vi således ikke kan minimere dette ved at ændre funktionsforskriften for m .

Det andet led kan omskrives til $f(X)\epsilon$, hvis forventede værdi er 0 (Følger af dekomposition Property at kovariansen mellem disses er nul og middelværdien af ϵ er nul).

Altså konstaterer vi at

$$\begin{aligned}\arg \min_{m(X)} E[(Y - m(X))^2] \\&= \arg \min_{m(X)} E[(E[Y|X] - m(X))^2]\end{aligned}$$

, hvilket åbenlyst har løsningen $m(X) = E[Y|X]$. Vi har hermed vist at CEF er en MMSE-løsning til afstanden til Y .

Potential outcomes framework

Vi tænker som altid på forskellene i de potentielle scenarier. Da vi i AEPE arbejder med to grupper (treated og ikke-treated) er de to potentielle scenarier / outcomes

Y_0 , i den (kontra)faktiske verden man ikke blev treated

Y_1 , i den (kontra)verden man blev treated

Således har vi fire kombinationer mellem potentialer og faktiske udfald

$Y_0|D = 0$: udfald i den verden man faktisk ikke blev treated

$Y_0|D = 1$: udfald i den verden man faktisk blev treated, hvis man ikke var blevet treated

$Y_1|D = 1$: Outcome i den verden man faktisk treate i

$Y_1|D = 0$: Udfald i den verden hvor man faktisk blev treated, hvis man ikke var blevet det

For at afdække ATT (Average Treatment effect for the Treated) skal vi kunne sammenligne gruppen der faktisk blev treated med den samme gruppe hvis de ikke var blevet treated.

Fx ph.d.-studerendes løn, hvis de ikke havde taget en ph.d. Dog kan vi kun sammenligne med andre personer uden ph.d.'er (i tværsnitssammenhænge) således må vi antage at disse personer har samme Y_0 , som dem med ph.d.'er havde. Altså at lønnen for disse personer uden ph.d.'er er lig lønnen for ph.d.'er hvis de ikke havde taget en ph.d. ph.d.:

$$E[Y_0|D = 0] = E[Y_1|D = 0]$$

For at bestemme **ATE** (Average Treatment Effect) skal vi antage at dem som blev treated har samme "gavn" af dette som dem der ikke er blevet treated ville have haft. OG at dem som ikke blev treated har samme udgangspunkt som dem der faktisk blev treated.

$$E[Y_0|D = 0] = E[Y_0|D = 1]$$

$$E[Y_1|D = 1] = E[Y_1|D = 0]$$

Måske lidt mere mundret kan vi tænke at Treatment effekten er ens for alle!

- ➔ Denne antagelse kan brydes hvis der er **seleksion** (altså at nogle mennesker som får mere ud af treatment eller i forvejen har bedre potentielle outcomes vælger at blive "treated". OLS vil derudover ikke kunne afdække dette hvis der forekommer **simultanitet / omvendt kausalitet**. Altså hvis dit udfald påvirker din treatment-status, hvis der er målefejl eller selektion (selvfølgelig).

Multiple lineær regression

Modellen

Vi forsøger som altid at modellere virkelighedens kausale strukturer. Vi antager her **linearitet i parametre**, altså ingen "**kryds-parametre**".

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u \quad (MLR. 1)$$

Notation: k forklarende variable, og $k+1$ parametre. Dette er en **semi-parametrisk** estimationsmetode, idet vi ikke antager nogen funktionel form af fejlleddet.

Motivation

Vi kan nu holde **effekterne af de k-1 andre variable fast** og undersøge den idiosynkratiske effekt af x_j på y . Derudover vil der **aldrig kun være én forklarende variable i den sande model**, således vil fejlleddet i alle praktiske sammenhænge være korreleret med de forklarende variable. Altså kan vi nærme os **eksogenitetskravet**: $E[u|x_1, x_2, \dots, x_k] = 0$.

Giver også mulighed for modeller med mere fleksible former:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + u$$

Kort sagt kan den multiple lineære regressionsmodel hive flere relationer (variable og deres koefficienter) ud af fejlleddet. Altså kan vi **kontrollere for flere uafhængige variable**.

MLR-estimatoren (moment-estimation)

Vi benytter MLR.4. til at udlede OLS-estimatoren. Man kan også gøre det ved at minimere den kvadrerede afvigelse mellem modellen og observationernes udfald.

$$\begin{aligned} E[u|x_1, x_2, \dots, x_k] &= 0 \\ \rightarrow \\ E[x_j u] &= E[E[x_j u|x_1, x_2, \dots, x_k]] = 0, \text{ for } x_j = 1, x_1, x_2, \dots, x_k \end{aligned}$$

Således har vi **k + 1 ligninger** til at bestemme k+1 parametre - altså er **OLS-estimatoren identificeret**.

Man kan opskrive ligningerne på matrixform:

Lad $\mathbf{x}_i$ være en $(k + 1) \times 1$ søjlevektor med de sædvanlige elementer for enhed 1, og lad $\mathbf{X}$ være en $(k + 1) \times n$ matrix defineret ved

$$\mathbf{X} = [x_1, x_2, \dots, x_n]$$

Til sidst har vi $(k + 1) \times 1$ søjlevektoren $\boldsymbol{\beta}$, som "smøres ud" over en vægtet sum af enhederne realiserede værdier. Altså man vægter hver realiseret værdi med det estimerede beta, for at predikterer y . Ved at antage MLR.4. kan vi udlede OLS-estimatoren vha. momentestimation:

$$E[\mathbf{x}u] = E[u, x_1 u, x_2 u, \dots, x_k u] = \mathbf{0} \quad (\text{Teoretisk MM})$$

$$\Leftrightarrow$$

$$\begin{aligned} E[u] &= 0 \\ E[x_j u] &= 0, \text{ for } j = 1, 2, \dots, k \end{aligned}$$

Ved at **erstatte de teoretiske momenter** (som kræver at man kender de stokastiske variables sande sandsynlighedsfordeling) med de **empiriske momenter** (som er konsistente estimatorer af de teoretiske momenter – hvis LLN gælder) har vi:

$$X\mathbf{u} = \begin{bmatrix} \sum_{i=1}^n 1 \cdot u_i \\ \sum_{i=1}^n x_{1i} u_i \\ \vdots \\ \sum_{i=1}^n x_{ni} u_i \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad (\text{Empirisk MM})$$

Vi kan isolere β i overstående ligningssystem:

$$\begin{aligned} Xu &= 0 \\ X(y - X'\beta) &= 0 \\ Xy - XX'\beta &= 0 \\ XX'\beta &= Xy \end{aligned}$$

$$\beta = (XX')^{-1}Xy \quad (\text{OLS})$$

Således antager vi også at XX' har **fuld rang**.

Bemærk. Jeg skriver notationen omvendt af mange lærebøger som definerer $X = [1, x_1', x_2', \dots, x_k']'$ Altså som en $(k + 1) \times n$ matrix. Således får vi

$$\begin{aligned} X'u &= 0 \\ \Leftrightarrow \\ \beta &= (X'X)^{-1}X'y \end{aligned}$$

Således skriver de også modellen som $y = Xb + e$ i stedet for $y = X'b + e$.

Fortolkning af parametre

Under MLR.4. fortolker vi en ændring i x_j som den kausale effekt af ændringen på y . Denne aflæses direkte ved parameterestimatet $\hat{\beta}_j$. Mere præcist er $\hat{\beta}_j$ den kausale ændring i den **forventede værdi af y** ved en stigning i x_j på én enhed.

Vi ser dette ved at kigge på populationsmodellen – som vi jo antager at alle observationer stammer fra:

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 + \dots \beta_k x_k + u \\ \Leftrightarrow \\ E[y|x_1, x_2, \dots, x_k] &= \beta_0 + \beta_1 x_1 + \dots \beta_k x_k \quad (\text{OLS} = \text{CEF}) \end{aligned}$$

Dermed har vi også

$$\begin{aligned} &E[y|x_1 + \Delta_1, x_2 + \Delta_2, \dots, x_k + \Delta_k] - E[y|x_1, x_2, \dots, x_k] \\ &= \\ &\beta_0 + \beta_1(x_1 + \Delta_1) + \dots \beta_k(x_k + \Delta_k) - (\beta_0 + \beta_1 x_1 + \dots \beta_k x_k) \end{aligned}$$

$$= \beta_1 \Delta_1 + \beta_2 \Delta_2 + \dots + \beta_k \Delta_k$$

Frisch-Waugh Teoremet (for $k = 2$)

Givet følgende model

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

Fås estimererne til β_1 ved først at regressere x_1 på x_2 og gemme residualerne $\hat{x}_1$. Disse regressere man y på. Intuitionen hænger sammen med alt-andet-lige fortolkningen: Først deler vi variationen i x_1 op i en del – der hænger systematisk sammen med x_2 . Denne del siger ikke isoleret set noget om variationen i y , så den skyller vi ud. Så tager vi den resterende variation – som ikke kan forklares ved x_2 . (denne variation tænker vi som ”så godt som” tilfældig – hvilket netop sikrer MLR.4). Vi kigger således på sammenhængen mellem $\hat{x}_1$ og y – som under modelantagelsen kan bruges til at estimere β_1 .

Generelt har vi for $\hat{\beta}_j$ i en model med k forklarende variable:

$$\hat{\beta}_j = \hat{\alpha}_j = \frac{\text{var}(\hat{x}_j, y)}{\text{var}(\hat{x}_j)}$$

Altså kan α_j fortolkes som parameteren i følgende estimation:

$$y = \alpha_j \hat{x}_j + e$$

, hvor $\hat{x}_j$ er den ”usystematiske del” som ikke korrelerer (hænger sammen) med de resterende forklarende variable. Altså er det fejlleddet fra følgende estimation

$$x_j = g_0 + g_1 x_1 + g_2 x_2 + \dots + g_{j-1} x_{j-1} + g_{j+1} x_{j+1} + \dots + g_{k-1} x_k + \hat{x}_j$$

Hvor $\hat{x}_j$ således er fejlleddet.

Mekaniske egenskaber ved OLS

Nogle egenskaber holder altid ved OLS – pr. definition. Det er simpelthen sådan den er udledt. Man skal dog ikke begynde at fortolke disse karakteristika men blot anerkende dem som algebraiske udfald.

De to første er rimeligt simple at overbevise sig selv om, idet vi præcist løser $\bar{u}$ ud fra betingelserne

$$\sum_{i=1}^n \hat{u}_i = 0 \quad (E[u] = 0)$$

$$\sum_{i=1}^n \hat{u}_i x_{ji} = 0, \text{ for } j = 1, 2, \dots, k \quad (\leftarrow E[u|X] = 0)$$

Gennemsnittet af de predikterede y 'er er lig gennemsnittet af de originale y 'er.

$$\frac{1}{n} \sum_{i=1}^n \hat{y}_i = \frac{1}{n} \sum_{i=1}^n y_i$$

Husk at $X'u$ -betingelsen også minimerer de kvadrerede fejlede (første element i den vektor den spytter ud er

$$\begin{aligned}\sum_{i=1}^n \hat{u}_i &= \sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n y_i - \sum_{i=1}^n \hat{y}_i = 0 \\ \Leftrightarrow \\ \frac{1}{n} \sum_{i=1}^n \hat{y}_i &= \frac{1}{n} \sum_{i=1}^n y_i\end{aligned}$$

Den sidste algebraiske egenskab magter jeg ikke skrive ned:

Punktet $(\bar{y}, \bar{x}_1, \bar{x}_2, \dots, \bar{x}_k)$ ligger på regressionslinjen dvs.
 $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}_1 + \hat{\beta}_2 \bar{x}_2 + \dots + \hat{\beta}_k \bar{x}_k$

Middelret (MLR.1-MLR.4)

Velkendte at this point...

Varians (MLR.1-MLR.5)

Variansen af OLS-estimatoren kræver en fordelingsantagelse om fejleddet – altså det uforklarede i modellen.

Vi antager at variansen er konstant: **homoskedasticitet** (husk at variansen er et mål for den forventede afvigelse fra middelværdien)

$$Var(u|x_1, x_2, \dots, x_k) = \sigma^2 \quad (MLR.5)$$

Vi antager også at have trukket variablene fra en **tilfældig stikprøve** og således har vi

$$Cov(u_i, u_j|x_i, x_j) = 0 \quad (MLR.2')$$

Altså at **mine idiosynkratiske og usystematiske variable der påvirker mit outcome y, ikke hænger sammen med andres idiosynkratiske og usystematiske variable**. Fx brydes denne hvis vi kigger på **to forskellige grupper i "populationen" som vi undersøger** – det kunne være efter uddannelsestrin eller geografisk placering. Så ville der i hver af disse grupper antageligvis være korrelationer mellem de uobserverede elementer – som også påvirker y!

Tilsammen giver MLR.2' og MLR.5

$$Var(\mathbf{u}|\mathbf{X}) = \sigma^2 \mathbf{I}$$

Altså kovarians-variansmatricen mellem alle enhedernes / observationernes fejleddet er givet ved variansen af alle enhedernes fejleddet – som er homoskedastiske.

Bevis OLS-estimatorens varians (under MLR.1 – MLR.5)

Vi benytter variansoperatoren til at bestemme hvordan vores $(k+1)$ parametre varierer – givet at fejleddet har en konstant varians – og givet nogle bestemte variabel-værdier. Altså er usikkerheden i realisationerne af X ikke relevante i følgende resultat:

$$\text{Var}(\hat{\beta}|X) = \text{Var}((X'X)^{-1}X'y|X) \quad (\text{OLS Indsat})$$

I beviset OLS er middelret dekomponeres OLS estimatoren til $\hat{\beta} = (X'X)^{-1}X'y = \beta + (X'X)^{-1}X'u$. Indsæt dette og benyt at $\text{Var}(\beta|X) = 0$.

$$= \text{Var}((X'X)^{-1}X'u|X) \quad (\text{Var}(\beta) = 0)$$

$$= (X'X)^{-1}X' \text{Var}(u|X) (X'X)^{-1}X' \quad (\text{Sandwich})$$

Vi bruger den konstante varians:

$$= (X'X)^{-1}X' \sigma^2 I ((X'X)^{-1}X')' \quad (\text{MLR. 2, .5})$$

Herfra er det blot at reducerer:

$$\begin{aligned} &= \sigma^2 (X'X)^{-1}X' ((X'X)^{-1}X')' \\ &= \sigma^2 (X'X)^{-1}X' (X')' ((X'X)^{-1})' \\ &= \sigma^2 (X'X)^{-1} \end{aligned}$$

Varians: $\hat{\beta}_j$ under MLR. 1 – MLR. 5

Man kan vise følgende (hvilket vi vist ikke gør i undervisningen):

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{SST_j(1 - R_j)} \quad (\text{Var})$$

, hvor $SST_j = \sum_{i=1}^n (x_{ji} - \bar{x}_j)^2$ og R_j^2 er R^2 værdien fra en lineære regression af x_j på alle de resterende $k-1$ forklarende variable.

Statistiske tests

For at udføre test skal vi antage en **specifik fordeling af fejleddet**. Den "klassiske" antagelse er

$$u \sim N(0, \sigma^2) \quad (\text{MLR. 6})$$

Således har vi fordelingen af $\hat{\beta}$ givet ved

$$\hat{\beta} = \beta + (X'X)^{-1}X'u \sim N(\beta, \sigma^2(X'X)^{-1})$$

Se afsnittet "Bevis OLS-estimatorens varians) for udledningen af variansen. Ellers brug den klassiske regneregul for lineære transformationer af n -dimensional normalfordelte variable:

$$Y = AX + b \sim N(A\mu + b, A\Sigma A')$$

Således er $\hat{\beta}$ normalfordelt med middelværdi β og varians $\sigma^2(X'X)^{-1}$. Dette er vel og mærk under CLM-antagelserne (MLR.1-MLR.6). Bemærk dog at MLR.6 (uafhængigt normalfordelte fejlede betinget på X) implicerer MLR.5, MLR.4 og MLR.3).

t-test

Når man vil teste hypoteser om middelværdien af normalfordelte variable kan t-testen benyttes. Da OLS-estimatoren $\hat{\beta}$ er asymptotisk normalfordelt under antagelse af i.i.d. fejlede, så kan vi normlisere denne og få at t-teststatistikken er.

Følgende opfylder CLM – antagelserne

Givet CLM har vi for OLS-estimatoren følgende

$$\frac{\hat{\beta}_j - \beta_j}{sd(\hat{\beta}_j)} \sim^a N(0,1) \quad (\text{Theorem 4.1})$$

Under CLM kan vi udskifte sd() med se() og få den t-fordelte teststatistik

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-(k+1)} = t_{df} \quad (\text{Theorem 4.2})$$

, hvor $se(\hat{\beta})$ er lig med variansen for OLS betinget på de forklarende variable, men hvor vi erkender ikke at kende den sande standardafvigelse og således må estimere denne:

$$se(\hat{\beta}) = \hat{\sigma}^2(X'X)^{-1} = \frac{\sum_{i=1}^n \widehat{u}_t^2}{n - (k + 1)}(X'X)^{-1}$$

Man kan også skrive

Dette giver for hver enkelt estimator:

$$se(\hat{\beta}_j) = \frac{\hat{\sigma}}{\sqrt{SST_j(1 - R_j)}} = \sqrt{\frac{\sum_{i=1}^n \widehat{u}_t^2}{df * SST_j(1 - R_j)}}$$

Varians: Fejleddet

En middelret estimator for den underliggende (antagede) proces' fejlede:

$$\widehat{\sigma^2} = \frac{\sum_{i=1}^n (u_i)^2}{n - k - 1} \quad (\text{Estimator: } \sigma^2)$$

Standardafvigelse: β_j

$$sd(\hat{\beta}) = \frac{\sigma}{SST_j(1 - R_j)} \quad (\text{Estimator: } sd)$$

Standardfejl: β_j

$$se(\hat{\beta}) = \frac{\hat{\sigma}}{SST_j(1 - R_j)} \quad (\text{Estimator: } se)$$

(CLT-fortolkningen)

Givet i.i.d. realisationer af n stokastiske variable $X_1, X_2, \dots, X_n$, hver med middelværdi $\mu = E[X_i] < \infty$ og varians $\sigma^2 = Var(X) < \infty$. Da er den empiriske middelværdi (gennemsnittet) af X 'erne asymptotisk normalfordelt med middelværdi $E[X]$ og varians $Var(x)/n$:

$$\overline{X}_n \sim^a N(E[X], Var(x)/n) = N(\mu, \frac{\sigma^2}{n}) \quad (\text{Asymptotisk CLT})$$

Hvis vi antager at **processen der danner fejleddet, består af en masse i.i.d. stokastiske variable, så er fejleddet selv normalfordelt** (og t test statistikken følger en t -fordeling med $n - (k+1)$ frihedsgrader, hvor n er antallet af realisationer og $k+1$ er antallet af parametre).

Vi kan også antage at fejleddene imellem hinanden er i.i.d. Således vil OLS-estimatoren være normalfordelt.

F-tests

Test flere af flere koefficienter på samme tid, fx:

$$H_0: \beta_1 = \beta_2 = \beta_4 = 0$$

$$H_A: \beta_j \neq 0, \text{ for } j = 1, 2, 4$$

Dette er en hypotesetest med et **tosidet alternativ**.

$$F = \frac{(SSR_r - SSR_{ur})/q}{SSR_{ur}/(n - k - 1)} \quad (F - \text{teststatistikken})$$

F-teststatistikken under CLM-antagelser

Hvis MLR.1-MLR.6 er opfyldt (CLM-antagelserne) er F teststatistikken F -fordelt:

$$F = \frac{(SSR_r - SSR_{ur})/q}{SSR_{ur}/(n - k - 1)} \sim F(q, n - k - 1)$$

, hvor q er antallet af lineære restriktioner, n er antal observationer og $(k+1)$ er antal parametre i den urestrikerede model

Idéen bag test af flere variable (intuition)

Vi sammenligner SSR i den urestrikerede model med SSR i den restrikerede. Vi vil altid se at SSR er højere i den restrikerede model, idet den har færre parametre at tilpasse udfaldene y . Således vil vi teste om SSR er tilpas uændret i den større model. Vi ser i overstående at vi sammenligner den relative vækst i variationen i den urestrikerede model ift. Den urestrikerede model.

Desto flere restriktioner = q , desto større variations-forskel er tilladt (F teststatistikken bliver mindre).

Hypoteser

Man opstiller altid sin nulhypotese på samme form. Ofte vil man teste om nogle variable er insignifikant (altså at én eller flere variable ligeså godt kunne være 0 – men tilfældigvis er blevet større eller mindre – grundet usikkerheden i resultatet).

Man kan tænke det som at holde sine estimationsresultater op imod den generelle variation som man forventer ved en statistisk model – der ikke rammer virkeligheden helt præcist.

Fremgangsmåden er simpelthen at postulere nogle værdier for parametrene:

$$H_0: \beta_1 = \beta_2 = \beta_4 = 0$$

Og specificere alternativet:

$$H_A: \beta_j \neq 0, \text{ for } j = 1, 2, 4$$

Det kunne også være én parameter:

$$H_0: \beta_2 = 3$$

$$H_A: \beta_2 \neq 3$$

Testning mod et énsidet alternativ

Overstående er den mest almindelige hypotesetest, men man kan også teste mod et énsidet alternativ:

$$H_0: \beta_2 = a$$

$$H_A: \beta_2 > a$$

Så afviser man kun hypotesen hvis værdien af t statistikken er tilpas høj. Husk under CLM-antagelserne har vi:

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k-1} \sim t_{df}$$

t-fordelingen har en middelværdi på 0 – givet at H_0 er sand. Hvis den sande værdi er i alternativhypotesens domæne: $\beta_j > a$, så vil t-statistikken forventes at antage en positiv værdi.

Altså kan vi **afvise nulhypotesen hvis t-statistikken er tilpas stor**. Det ville være omvendt for en negativ énsidet hypotesetest: $H_A: \beta_j < a$.

Således skal vi bestemme den kritiske værdi som lader os afvise nulhypotesen til fordel for alternativhypotesen:

$$t_{\hat{\beta}_j} > c$$

Givet et **signifikansniveau på 0.05 (5 pct.)** og fx 28 frihedsgrader har vi den kritiske værdi **1,701 (den værdi, hvor alle større værdier kun antages med ssh. givet ved signifikansniveauet)**

Heteroskedasticitet

Fejlledet afhænger af de forklarende variable 😊

IV estimation

Vi har ikke adgang til nok kontrollerende variable. Således er vi begrænset til at køre en "short regression", hvor vi ikke har alle relevante uafhængige variable med.

Variablen som er korreleret med fejlleddet kaldes **endogen**. Desuden kaldes variable som netop ikke er korreleret med fejlleddet **eksogene**. Jeg tænker det som at de eksogene mere frie til at sætte værdier (netop fordi vi kontrollerer for alle relevante sammenhænge, hvorimod endogene variable ikke er fast bestemt – på den måde at fejlleddet også har haft en ukendt indflydelse på den endogene variabel.

En short regression for løn kunne være

$$\ln y = X\beta + u \quad (\text{Short})$$

, hvor fx $\text{cov}(u, x_{\text{udd}}) \neq 0$. Dog kunne vi forestille os at følgende long regression kunne løse problemet. Her tager vi højde for individets evner (ability).

$$\ln y = X\beta + A\beta_A + e_i \quad (\text{Long})$$

, hvor $\text{cov}(u, x_i) = 0$, for $i = 1, 2, \dots, k$.

Fortolkningen er at "evner er den eneste grund til at uddannelse er korreleret med potentielle outcomes" (ift. (Short) regressionen). Netop fordi fejlleddet siger noget om potentielle outcomes: En med et "stort" fejledd i overstående regressioner vil have både højere Y_1 og Y_0

- ➔ Som er potentielle outcomes i verdenen hvor vedkommende blev uddannet, og ikke blev. Man kan også fortolke det som et spektrum. Altså $Y_1, Y_2, Y_3, \dots, Y_{PHD}$. Hvis der ikke er systematiske sammenhænge mellem de forklarende variable og fejlleddet (og modellen er nogenlunde korrekt specificeret)

Gyldigt instrument

VI har to krav til et nyttigt instrument. Det skal være relevant (altså faktisk hænge sammen med den endogene x). Derudover skal det være "eksogent" altså ikke påvirke fejleddet den korte regression / hovedregressionen

$$\begin{aligned} cov(y, z) &= 0 \\ cov(x, z) &\neq 0 \end{aligned}$$

Hvis man finder en variabel z som opfylder overstående, da kan IV estimation benytte til at afdække den kausale effekt af x på y . Netop fordi noget af variationen i x er tilfældigt betinget af z variabelen. Jeg kalder det tilfældigt da z -værdien ikke påvirker de uobserverede egenskaber ved enhed i (individ i).

IV estimatoren

Herunder udleder vi populationskoefficienten. Lad $y = \alpha + \beta x + u$, være populationsmodellen (vi kunne sagtens tillade kontroller), hvor x er endogen ($cov(x, u) \neq 0$). og lad z være et instrument for x . Da er IV estimatoren defineret ved:

$$\begin{aligned} cov(y, z) &= cov(\alpha + \beta^{IV} x + u, z) = \beta^{IV} cov(x, z) \\ &\Leftrightarrow \\ \beta^{IV} &= \frac{cov(y, z)}{cov(x, z)} \end{aligned} \quad (IV - POP)$$

Ved at indsætte empiriske momenter (estimator for kovarianserne) fås IV estimatoren, som den bruges på data i dette simple tilfælde (just identified case).

$$\widehat{\beta}^{IV} = \frac{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})(z_i - \bar{z})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z})} \quad (IV)$$

IV er konsistent (simpel regression)

Antag at populationsmodellen er givet ved

$$y = \alpha + \beta x + u \quad (SLR. 1)$$

(MLR.2) at observationerne er uafhængige (fx ved at være en tilfældigt udtrukket stikprøve af befolkningen) og identisk fordelt.

(3. antagelse) z er et gyldigt instrument for x . dvs.

$$cov(x, z) \neq 0 \quad (Testable)$$

$$cov(u, z) = 0 \quad (Untestable)$$

Hvis overstående er opfyldt, så gælder

$$plim \widehat{\beta}^{IV} = \beta$$

(Konsistent)

, hvor vi definerer følgende IV estimator – hvilket er en skalar:

$$\widehat{\beta}^{IV} = \frac{\frac{1}{n} \sum_{i=1}^n (y - \bar{y})(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n (x - \bar{x})(z - \bar{z})}$$

Bevis: Beviset forløber helt tilsvarende alle andre: Vi antager at kende populationsmodellen, og reducerer udtrykket til et led med den sande parameter og "noget ekstra".

STEP ONE: OMSKRIVNING:

$$\begin{aligned} \widehat{\beta}^{IV} &= \frac{\frac{1}{n} \sum_{i=1}^n (y - \bar{y})(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n (x - \bar{x})(z - \bar{z})} \\ &= \frac{\frac{1}{n} \sum_{i=1}^n y(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} && (\text{Regnereg}) \\ &= \frac{\frac{1}{n} \sum_{i=1}^n (\alpha + \beta x + u)(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} && (MLR. 1.) \\ &= \frac{\frac{1}{n} \sum_{i=1}^n \alpha(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} + \frac{\frac{1}{n} \sum_{i=1}^n \beta x(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} + \frac{\frac{1}{n} \sum_{i=1}^n u(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} \\ &= \alpha \cdot 0 + \beta \cdot 1 + \frac{\frac{1}{n} \sum_{i=1}^n u(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} \\ &= \beta + \frac{\frac{1}{n} \sum_{i=1}^n u(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} \end{aligned}$$

STEP TWO: SANDSYNLIGHEDSGRÆNSEN:

$$\begin{aligned} p \lim \beta^{IV} &= \beta + p \lim \left(\frac{\frac{1}{n} \sum_{i=1}^n u(z - \bar{z})}{\frac{1}{n} \sum_{i=1}^n x(z - \bar{z})} \right) \\ &= \beta + \frac{p \lim \left(\frac{1}{n} \sum_{i=1}^n u(z - \bar{z}) \right)}{p \lim \left(\frac{1}{n} \sum_{i=1}^n x(z - \bar{z}) \right)} && (\text{Regnereg}) \\ &= \beta + \frac{cov(u, z)}{cov(x, u)} && (i. i. d) \\ &= \beta + \frac{0}{cov(x, u)} && (z \text{ antagelse}) \\ &= \beta \end{aligned}$$

Hermed er det ønskede bevist!

[FIRKANT!]

OLS estimation versus IV estimation

Igen er dette under antagelserne *SLR. 1, MLR. 2 og i. i. d*

$$p \lim \beta^{IV} = \beta + \frac{\text{cov}(u, z)}{\text{cov}(x, u)} \quad (IV)$$

$$p \lim \beta^{IV} = \beta + \frac{\text{cov}(y, x)}{\text{cov}(x)} \quad (OLS)$$

IV estimation med $I < k$ endogene variable

Nu vil vi undersøge tilfældet med $I < k$ endogene variable $\text{cov}(x_j, u) \neq 0$ for $j = 1, 2, \dots, I < k$ og $k - I$ eksogene variable $\text{cov}(x_j, u) = 0$ for $j = I + 1, I + 2, \dots, k$.

Ved at bruge den velkendte matrix-notation $y = X\beta + u$ har vi således X givet ved

$$\mathbf{X}_{n \times k} = \begin{pmatrix} x_1, x_2, \dots, x_I & x_{I+1}, \dots, x_k \\ I \text{ endogene} & k-I \text{ eksogene} \end{pmatrix}$$

, hvor de første I variable er endogene og de sidste $k - I$ variable er eksogene. Endogenitet kan også defineres således

$$p \lim \left(\frac{1}{n} \sum_{i=1}^n x_{ij} u_i \right) \neq 0 \text{ for } j = k - I + 1, \dots, k.$$

Eksakt identifikation (IV-estimator)

I dette tilfælde har vi præcist lige så mange instrumenter som endogene variable

$$\mathbf{Z}_{n \times k} = \begin{pmatrix} z_1, z_2, \dots, z_I & x_1, x_2, \dots, x_I \\ I \text{ instrumenter} & k-I \text{ eksogene} \end{pmatrix}$$

Ligesom med OLS løser vi IV-estimationens estimator ved **moment-betingelsen**. Denne siger netop at den **empiriske (parvise) kovarians mellem alle fejlede (observeret usystematisk heterogenitet) u og alle eksogene variable (x 'erne) og alle instrumenterne (z 'erne) skal være lig nul** – som stammer fra antagelsen om at regressionsmodellen er CEF $E[y|Z]$.

$$\begin{aligned} Z'u &= 0 \\ Z'(y - X\hat{\beta}) &= 0 \\ Z'y - Z'X\hat{\beta} &= 0 \end{aligned}$$

$$\hat{\beta}^{IV} = (Z'X)^{-1}Z'y \quad (IV - estimator)$$

Dette giver et helt cooked udtryk: (se slutningen af afsnittet her, for intuition)

$$(Z'X)^{-1}Z'y = \left(\begin{bmatrix} \sum_{i=1}^n z_{1i}x_{1i} & \sum_{i=1}^n z_{1i}x_{2i} & \cdots & \sum_{i=1}^n z_{1i}x_{ki} \\ \sum_{i=1}^n z_{2i}x_{1i} & \sum_{i=1}^n z_{2i}x_{2i} & & \sum_{i=1}^n z_{2i}x_{ki} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n z_{ki}x_{1i} & \sum_{i=1}^n z_{ki}x_{2i} & \cdots & \sum_{i=1}^n z_{ki}x_{ki} \end{bmatrix} \right)^{-1} \begin{bmatrix} \sum_{i=1}^n y_i z_{1i} \\ \sum_{i=1}^n y_i z_{2i} \\ \vdots \\ \sum_{i=1}^n y_i z_{ki} \end{bmatrix}$$

Mettes mere korrekte udledning, hvor vi først kigger på de teoretiske momenter, og erstatter disse med de empiriske:

Vi tager udgangspunkt i den teoretiske betingelse:

$$\begin{aligned} p \lim \frac{1}{n} Z' u &= \mathbf{0} \\ p \lim \left(\frac{1}{n} Z' (y - X\beta) \right) &= \mathbf{0} \\ p \lim \left(\frac{1}{n} (Z'y - Z'X\beta) \right) &= \mathbf{0} \end{aligned}$$

Hvis vi erstatter de teoretiske momenter med datamomenter, får vi:

$$\begin{aligned} Z'y - Z'X\hat{\beta}^{IV} &= \mathbf{0} \\ Z'y &= Z'X\hat{\beta}^{IV} \\ \hat{\beta}^{IV} &= (Z'X)^{-1}(Z'y) \end{aligned}$$

Bemærk at dette har en lækker intuitiv fortolkning. Dette bestemmes ved at kigge på "regressions-anatomien"

$$\hat{\beta}_j = \frac{cov(y, \tilde{z})}{cov(\tilde{x}, \tilde{z})} \quad (IV - anatomi)$$

, hvor tilde variablene kommer fra en regression af disse variable på de øvrige forklarende variable.

Overidentifikation (2SLS - estimator)

Hvis vi i stedet har **flere instrumenter end endogene variable**, kunne man måske overveje at benytte de instrumenter som bedst giver eksogen variation i de endogene variable. Dog kan vi få **mere eksogen variation ved at benytte alle instrumenterne** - medmindre instrumenterne er *perfekt* korellerede med hinanden. Mere variation $\Rightarrow$ mere præcise estimater.

I tilfældet med flere instrumenter end endogene variable kaldes det "overidentificeret", da vi identificerer et estimat for β ved det eksakt identificerede tilfælde. Variabel-matricen ser nu således ud

$$\underset{n \times k-1+g}{Z} = \begin{pmatrix} z_1, z_2, \dots, z_I, \dots, z_g & x_1, x_2, \dots, x_I \\ \underset{g > I \text{ instrumenter}}{} & \underset{k-I \text{ eksogene}}{} \end{pmatrix}$$

Nu kan vi ikke længere (generelt) løse

$$Z'u = 0$$

Også selvom de generelle antagelser for instrument variabel estimation er overhold. Dette skyldes simpelthen at 3 ligninger med 2 ubekendte ikke nødvendigvis har et entydigt svar.

Generelle antagelser for IV estimation (matrix notation)

Husk at Z både kan være $n \times k$ med eksakt identifikation og $n \times (k - I + g)$, hvor $g > I$ i det overidentificerede tilfælde.

"Eksogene" instrumenter

$$p \lim \frac{1}{n} (Z'u) = \mathbf{0}$$

Relevante instrumenter

Kovarians-variansmatrixen (den empiriske) mellem X'erne og Z'erne skal have fuld rang.

$$p \lim X'Z = \Sigma_{XZ} \text{ har fuld rang}$$

Matrixen $X'Z$ indeholder alle parvise prikprodukter mellem søjler i Z og søjler i X. Da søjlerne netop indeholder alle observationer for en given variabel (og da vi antager i.i.d) da finder vi den empiriske kovarians / varians (alt efter om $i = j$).

Således er der en korrelation mellem alle instrumenterne og de endogene variable.

Invertibel instrument-matrix

Ingen instrumenter må være perfekt korreleret med hinanden. Altså ingen perfekt multikollinearitet mellem instrumenterne.

Tidsrækker

Tidsrækker III- Forelæsningsplan

- 1) OLS estimatoren
 - a. Konsistent
 - b. Middelret
 - c. Asymptotisk fordeling
- 2) Misspecifikationstest
 - a. Autokorrelation
 - b. Heteroskedasticitet
 - c. Funktionel form
 - d. Normalitet

OLS estimatoren (Recap)

Kan som altid bestemmes vha. MM (Method of Moment), hvor vi benytter (følgende er skalarer for enhed i)

$$E[u] = 0, E[u|x] = 0 \rightarrow E[ux] = 0 \quad (T.1)$$

Således har vi nemlig $k + 1$ ligninger til at bestemme de $k + 1$ ubekendte parametre. Lad X være $n \times (k + 1)$ og β være $(k + 1) \times 1$ så kan vi opskrive MM-ligningerne som (T.1)

$$X'u = 0 \quad (T.2)$$

Netop fordi matrixproduktet er prikproduktet mellem den i 'te række i X' og de estimerede fejl for alle individerne. Således fås det **empiriske centrale moment af 2. orden** nemlig middelværdien.

Fx er tredje element i (T.2) givet ved (husk første række i X' blot er 1-taller associeret med β_0). Syntaksen er enhed i , variabel j x_{ij} (kan således også fortolkes som række i , søjle j i matricen X)

$$x_{12}\widehat{u}_1 + x_{22}\widehat{u}_2 + x_{32}\widehat{u}_3 + \dots + x_{n2}\widehat{u}_n = \sum_{i=1}^n x_{i2} \widehat{u}_i = 0 \quad (T.3)$$

Selvfølgelig kunne man skalere dette med $1/n$, som ikke ville påvirke løsningen. Altså er (T.3) ækvivalent med at **sætte den empiriske kovarians lig nul mellem alle de forklarende variable og fejleddet**. Således er estimatoren også *kun* retvisende hvis denne fundamentale antagelse er overholdt.

Ved at **løse (T.2)** fås

$$\begin{aligned} X'u &= X'(y - X\beta) = X'y - X'X\beta = 0 \\ &\Leftrightarrow \\ \beta &= (X'X)^{-1}(X'y) \end{aligned} \quad (T.4)$$

, hvor $(X'X)^{-1}$ er $(k + 1) \times (k + 1)$ og $X'y$ er $(k + 1) \times 1$ – en søjlevektor.

Bemærk desuden at element (j, k) i $X'X$ er givet ved

$$(X'X)_{jk} = \sum_{i=1}^n (X')_{ji} X_{ik} \quad (T.5)$$

Altså prikproduktet af den j 'te række i X' og den k 'te søjle i X . Da vi har $(X')_{ji} = X_{ij}$ er (T.5) således en slags varians / kovarians – bare ikke de-meanet.

Bemærk at (T.5) også giver os muligheden for at omskrive følgende $(k+1)$ søjle hhv. række vektor

$$x_i, x_i' \quad (T.6)$$

, hvor det (j,k) 'te element er givet ved

$$x_{jk} = x_{ij} \cdot x_{ik}$$

Således kan vi summe (T.6) og få hvert element som i (T.5). Altså har vi den empiriske moment-estimator givet ved

$$\begin{aligned} \hat{\beta} &= \left(\sum_{i=1}^n (x_i x_i') \right)^{-1} \left(\sum_{i=1}^n x_i y_i \right) \\ &= \left(\frac{1}{n} \sum_{i=1}^n (x_i x_i') \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) \end{aligned}$$

Vi skal som **altid benytte en udgave af LLN** (Law of Large Numbers) til at bedømme om beta-estimatoren er **konsistent** – altså går mod den sande værdi.

OLS estimatoren for tidsrækker

Tidsrækkedatasættet består af k forklarende variable observeret i T perioder (fra $t = 1$ til $t = T$). Vi antager i tværsnits-data at disse er identisk fordelt (genereret ud fra samme populationsmodel / natur-model). I tidsrækkeøkonometri virker denne antagelse simpelthen for crazy.

- ➔ For selvom **det uobserverede led u** (som påvirker udfaldet y) **ikke nødvendigvis betyder noget** for de forklarende variable **i indeværende periode** (systematisk), så vil høje værdier af de uforklarede variable højst sandsynligt betyde noget for de forklarende variables værdier i **næste periode**.

Streng eksogenitet antages derfor (næsten) aldrig at holde i tidsrækkedata.

Bevis: Simpel OLS er konsistent

Vi vil vise at følgende gælder

$$p \lim_{t \rightarrow \infty} \hat{\beta} = \beta$$

Under antagelserne

TS.1. Den sande model er givet ved

$$y_t = \beta x_t + u \quad (TS.1)$$

TS.2. Eksogent fejld i samme periode

$$E[u_t | x_t] = 0 (\rightarrow E[x_t u_t] = 0) \quad (TS.2)$$

TS.3. **Variation:** Der skal være noget variation i nogle af variablene (således at variabel-matrixen har fuld rang)

TS.4. **Stationaritet og svag afhængighed.** Dette svarer lidt til identisk fordelt antagelsen samt uafhængighed mellem observationer (som i tværsnit er en tilfældig stikprøve).

Type equation here.

Formelt siger svag Stationaritet følgende

$$E[Y_t] = \mu < \infty$$

$$V(Y_t) = E[(Y_t - \mu)^2] = \gamma_0 < \infty$$

$$\text{Cov}(y_t, y_{t+k}) = E[(Y_t - \mu)(Y_{t+k} - \mu)] = \gamma_k$$

I ord: Middelværdien er uafhængig af tidspunktet (dvs. man ikke kan sige noget om middelværdien ude

Gentagende tværsnit

Nu begynder vi at beskæftige os med datasæt som indeholder flere tidsperioder. Altså er der ikke blot individ-dimensionen, men også tidsdimensionen.

Vi antager at have en tilfældig stikprøve fra populationen (den population vi studerer) i periode t givet ved

$$(y_{it}, x_{it1}, x_{it2}, \dots, x_{itk})$$

, for $i = 1, 2, \dots, n$. Dette kan vi gøre for mange perioder: Både hvor vi måler de samme enheder igen og således bedre kan kontrollere for enhedsspecifikke egenskaber / karakteristika, eller vil tilfældigt at trække flere gange. Det sidstnævnte tilfælde undersøger vi først:

Uafhængige gentagende tværsnitsobservationer

Dette er datasæt som kan svare på tidsspecifikke spørgsmål. Fx om parameterverdierne har ændret sig over tid (ved et robust F-test)

Man kan fx tillade for forskellige konstantled ved at tilføje en tidsdummy:

$$y_i = \beta_0 + \delta_0 \cdot D_t + \beta_1 x_{it1} + \dots + \beta_k x_{itk} + u_{it}$$

Eller lave tidsdummies for alle parametrene

$$\begin{aligned} y_i = & \beta_0 + \delta_0 d2_i \\ & + \beta_1 x_{1i} + \delta_1 d2_i x_{1i} \\ & + \beta_2 x_{2i} + \delta_2 d2_i x_{2i} \\ & \dots \\ & + \beta_k x_{ki} + \delta_k d2_i x_{ki} + u_i \end{aligned}$$

Hypotese $H_0 : \delta_0 = \delta_1 = \dots = \delta_k = 0$. (Ingen ændring i parametrene).

Her tester vi således **parameterstabilitet**.

Difference in difference

Difference in difference er mere grov end fx FE eller FD estimation. Dette skyldes at DiD benyttes til data på mere aggregeret niveau. Altså hvis der sker ændringer som ikke varierer mellem individer i forskellige grupper. Ofte vil dette fremkomme ved politik-ændringer, netop fordi alle i en region udsættes for treatment. Her er problemet så:

Hvordan adskiller vi effekten af treatment (lovændringen) fra generelle tids-variable?

- ➔ Helt lavpraktisk er treatment-indikatoren perfekt korreleret med tidsdummien. Således kan vi højst få et gennemsnit af effekten vha. standard OLS indenfor hver region.

Løsning: Vi benytter en anden region, som ikke er udsat for lovændringen, som proxy for det potentielle udfald, som byen med politikændringen *ville have oplevet, hvis politikken ikke var gennemført*.

Den kritiske antagelse! Er at vi finder en kontrolgruppe som har samme udvikling i outcome variablen, som den treatede gruppe ville have haft. Således kan vi nemlig fjerne denne effekt fra den samlede treatment og "andet" effekt.

Paneldata

I Økonometri I arbejder vi med **balanceret panel** data (lige mange observationer pr. individ = hver enhed er observeret i samme antal perioder).

Altså er datasættet beskrevet ved følgende

$$(y_{it}, x_{it1}, x_{it2}, \dots, x_{itk}), \text{ for } i = 1, 2, \dots, n \text{ og } t = 1, 2, \dots, T$$

Hvorfor er paneldata smart?

Ligesom med gentagende tværsnit har vi mulighed for at undersøge tidseffekter. Fx om parametre har ændre sig over tid (parameterstabilitet), samt adskille effekter fra politikker og tid (hvis man har mindst to områder: Én som oplevede en politik ændring og én der ikke gjorde)

- Egentligt behøver der ikke være to **områder** der skal blot være to **grupper: En treatment og kontrolgruppe**. Igen er den kritiske antagelse (for at afdække ATE) at treatmentgruppen ville have haft samme udvikling som kontrolgruppen.

Med paneldata kan vi dog kontrollere for mere end "aggregeret forskelle" (altså forskel mellem grupper, fx aldersgrupper eller bosted). Her kan vi kontrollere for personspecifik heterogenitet. Dog antager vi stadig **homogen treatment effect**: Altså at enheder som faktisk ender med at blive treated har samme gevinst (eller tab) ved denne treatment. Fx uddannelsesniveau. Her kan vi fjerne generel "evne" vha. paneldata, men for at vi estimerer ATE skal vi antage at personerne med højere uddannelse har samme afkast af dette som personer med lav uddannelse *villa have haft*.

- Dog kan vi godt finde ATT ved blot at antage at det potentielle outcome i et tilfælde med lav / ingen uddannelse ville være ens når vi kontrollerer for evner. Altså er det kun "treatment effekten" der er forskellig mellem grupperne men ikke "untreated udfaldet".

First difference estimator (antagelser)

Lad os først antage at data er genereret ud fra følgende model, hvor vi har en tilfældig stikprøve fra samme population (parametrene er ens) – dette er tilsvarende MLR.1 og MLR.2:

$$y_{it} = \beta_0 + \beta_1 x_{it1} + \beta_2 x_{it2} + \dots + \beta_k x_{itk} + u_{it}, \text{ for } t = 1, 2 \quad (DGP)$$

, hvor $u_{it} = a_i + \epsilon_{it}$.

Vi opstiller FD estimatoren der – som navnet antyder – **tager forskellen mellem de to tidspunkter for hvert individ**.

$$\Delta y_i = \beta_0 + \beta_1 \Delta x_{i1} + \beta_2 \Delta x_{i2} + \dots + \beta_k \Delta x_{ik} + \Delta u_i, \quad (FD)$$

Ved at lave en mindre definition bliver udtrykket meget genkendeligt: Lad $\Delta a_i = \tilde{a}_i$, så har vi

$$\tilde{y}_{i1} = \beta_0 + \beta_1 \tilde{x}_{i1} + \beta_2 \tilde{x}_{i2} + \dots + \beta_k \tilde{x}_{ik} + \Delta u_i, \quad (FD)$$

Denne er middelret og konsistente under følgende antagelser

FD.1. Populationsmodellen er lineær i parametre:

$$y_{it} = \beta_0 + \beta_1 x_{it1} + \beta_2 x_{it2} + \dots + \beta_k x_{itk} + u_{it}, \text{ for } t = 1, 2 \quad (FD.1)$$

FD.2 datasættet er en tilfældig stikprøve fra populationen (i.i.d). Således vil FD.4 være langt mere plausibel idet

$$\begin{aligned} E[\Delta u_{i=a} | \Delta x_{i1}, \Delta x_{i2}, \dots, \Delta x_{ik}] &= 0, \text{ for } i = 1, 2, \dots, n \\ &= E[\Delta u_{i=a} | \Delta x_{i1}, \Delta x_{i2}, \dots, \Delta x_{ik}] = 0, \text{ for } i = a \end{aligned}$$

(siger bare at andres x 'ere ikke har indflydelse på mine u 'ere netop fordi observationerne er uafhængige). Dette gør desuden også inferens "nemmere" da kovarians leddene således antages at være nul.

FD.3 der er variation for nogle individer i alle variablene. Helt tilsvarende MLR.3 er dette mest af alt en sanity-check antagelse, som sikre at (den empiriske kinda-) kovarians-varians-matricen $(\tilde{X}'\tilde{X})$ er invertibel. (bemærk denne er kun "kinda" den empirisk kovarians-varians-matrix, da man ikke dividerer med antallet af enheder nemlig n).

FD.4 Words are un-ne-ces-sary (they can only do harm):

$$E[\Delta u_i | \Delta x_{i1}, \Delta x_{i2}, \dots, \Delta x_{ik}] = 0$$

Bevis at FD - OLS er middelret

Udled OLS estimatoren vha. MM (Method of Moments) – Her benyttes FD.3:

$$\begin{aligned} \tilde{X}'\mathbf{u} &= \mathbf{0} \\ \tilde{X}'(\mathbf{y} - \hat{\mathbf{y}}) &= \mathbf{0} \\ \tilde{X}'(\mathbf{y} - \tilde{X}\hat{\boldsymbol{\beta}}^{\text{FD}}) &= \mathbf{0} \\ \tilde{X}'\mathbf{y} - \tilde{X}'\tilde{X}\hat{\boldsymbol{\beta}}^{\text{FD}} &= \mathbf{0} \end{aligned}$$

$$\hat{\boldsymbol{\beta}}^{\text{FD}} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\mathbf{y}$$

Omskriv den vha. FD.1:

$$\begin{aligned} \hat{\boldsymbol{\beta}}^{\text{FD}} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'(\tilde{X}\boldsymbol{\beta} + \mathbf{u}) \\ &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{X}\boldsymbol{\beta} + (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\mathbf{u} \\ &= \boldsymbol{\beta} + (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\mathbf{u} \end{aligned}$$

Tag den betingede middelværdi betinget på de forklarende variable (hvis dette er en konstant vil den ubetingede middelværdi være denne værdi jf. LIE) – Her benyttes både FD.2 og FD.4:

$$\begin{aligned} E[\hat{\boldsymbol{\beta}}^{\text{FD}} | \tilde{X}] &= \boldsymbol{\beta} + E[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\mathbf{u} | \tilde{X}] \\ &= \boldsymbol{\beta} + (\tilde{X}'\tilde{X})^{-1}\tilde{X}'E[\mathbf{u} | \tilde{X}] \\ &= \boldsymbol{\beta} + (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\mathbf{0} \\ &= \boldsymbol{\beta} \end{aligned}$$

For god ordens skyld har vi så også $E[\hat{\boldsymbol{\beta}}^{\text{FD}}] = E[E[\hat{\boldsymbol{\beta}}^{\text{FD}} | \tilde{X}]] = E[\boldsymbol{\beta}] = \boldsymbol{\beta}$.

FD-estimator konsistens (med T tidsperioder)

I det mere generelle tilfælde med T tidsperioder kan vi vise at estimatoren er middelret under FD.1-FD.3 og

$$E[u_{it}|X_i] = 0 \quad (\text{Streng eksogenitet})$$

, hvor X_i er en matrix med tværssnitsdata for enhed i . Dvs. alle enhed i 's forklarende variable i perioderne $t = 1, 2, \dots, T$. Således udelukkes der også korrelation mellem fx fejleddet i periode $t = 2$ og de forklarende variable i alle fremtidige periode.

- ➔ Implikerer at ingen forklarende variable må være laggede variable af den uafhængige variabel y – altså modellen må ikke være autokorreleret. Netop fordi y i foregående periode påvirkes af u i foregående periode, som igennem den laggede struktur også påvirker y i den næstkommende periode.
- ➔ Derudover udelukker antagelsen om **streng eksogenitet** at de forklarende variable selv afhænger af y (på en lagged måde). Altså selvom et fx højt y i indeværende periode ikke medfører høje (eller lave) x 'ere i indeværende periode, kan det jo godt påvirke næste periodes x 'ere.