



Økonometri I - Ugeseddel 10

Paneldata & pensions effekt på tilbagetrækningsalder

Casper Moes | hwd362@econ.ku.dk & memetrics@gmail.com

Københavns Universitet | Økonomisk institut | F26

\begin{undervisning}

Gennemgang af Hjemmeopgave 3

Introduktion til panel-data og ugesedlen

(pause)

Gruppearbejde

Introduktion til nye STATA kommandoer

(pause)

STATA øvelser (45 min.)

\end{undervisning}

Hjemmeopgave 3



Opgave 1

Opgave 1.a og 1.b

- ▶ Flot arbejde!
- ▶ Nævn eksplicit at modellen er en lineær sandsynlighedsmodel (fordi den afhængige variabel er en dummy).
- ▶ Brug hintet skamfrit (nogle få definerer FP_i forkert)

Opgave 1.c

- ▶ HUSK at påtale valg af standardfejl! <3
- ▶ For lineære sandsynlighedsmodeller har vi:

$$\begin{aligned} V(u_i|x_i) &= V(y_i - (\beta_0 + x_i\beta_1)|x_i) = V(y_i|x_i) = E[y_i^2|x_i] - (E[y_i | x_i])^2 \\ &= P(y_i^2 = 1 | x_i) - P(y_i = 1 | x_i)^2 = P(y_i = 1 | x_i) - P(y_i = 1 | x_i)^2 \end{aligned}$$

Altså ikke konstant varians, hvis modellen har forklaringskraft sådan at $P(y_i = 1 | x_i) \neq \text{KONSTANT}$ for alle x_i .

IV antagelser

Opgave 2 (a)

Mange er usikre på betingelserne for en konsistent IV-estimator (når der inkluderes eksogene forklarende variable).

Fra noten (hvor de første l søjler i Z er instrumenter og de resterende er eksogene kontrolvariable) har vi betingelserne:

$$\text{plim } \frac{1}{n} Z'u = 0 \quad (\text{validt})$$


$$\text{plim } \frac{1}{n} Z'X = \Sigma_{ZY}, \text{ har fuld rang} \quad (\text{relevant})$$

I det eksakt identificerede tilfælde (som i opgaven) fås

$$\frac{1}{n} Z'u = \frac{1}{n} Z'(y - X\hat{\beta}) = 0 \iff \hat{\beta} = \left(\frac{1}{n} Z'X \right)^{-1} \left(\frac{1}{n} Z'y \right) \implies$$

$$\text{plim } \hat{\beta} = \text{plim } \left(\frac{1}{n} Z'X \right)^{-1} \text{plim } \left(\frac{1}{n} Z'y \right) = \beta + \text{plim } \left(\frac{1}{n} Z'u \right) = \beta$$

Figur 1: Histogram over prædikterede sandsynlighed for tidlig død.



Note: Tidlig død defineres som død inden 70 år.

Kilde: Udleveret, konstrueret data.

Figure 1: Opgave 2.c

Generelt har folk ret godt styr på opgave 3 - dog er 3.a lidt farlig:

[...]. Diskuter hvorfor der indgår færre observationer i denne regression end i regressionen for model (1) og overvej, om det kan være et problem.

Hvornår er det et problem? Hvis dem der overlever har et systematisk anderledes læge-besøgsmønster **på grund af** $pension66$.

For eksempel hvis tidlig pension får relativt svage individer til at overleve. Så vil kohorten med $pension66_i = 1$ bestå af relativt svagere individer sammenlignet med kohorten med $pension66_i = 0$.

Opgave 4

I "konsistens"-opgaver skal i **altid anvende LLN**. Gør det så "hurtigt som muligt": Vi skal beregne $\tilde{\beta}_1 = \frac{\bar{y}^{d=1} - \bar{y}^{d=0}}{\bar{x}^{d=1} - \bar{x}^{d=0}}$. Først kigger vi på tælleren:

$$\begin{aligned}\bar{y}^{d=1} - \bar{y}^{d=0} &= \frac{\sum y_i d_i}{\sum d_i} - \frac{\sum y_i (1 - d_i)}{\sum 1 - d_i} \\ \xrightarrow{p} \frac{E[y_i d_i]}{E[d_i]} - \frac{E[y_i (1 - d_i)]}{E[1 - d_i]} &= \frac{E[1 - d_i]E[y_i d_i] - E[d_i]E[y_i (1 - d_i)]}{E[d_i]E[1 - d_i]}\end{aligned}$$

Brug at $V(d_i) = E[d_i^2] - E[d_i]^2 = E[d_i](1 - E[d_i])$:

$$\begin{aligned}\frac{E[1 - d_i]E[y_i d_i] - E[d_i]E[y_i (1 - d_i)]}{E[d_i]E[1 - d_i]} &= \frac{E[y_i d_i] - E[d_i]E[y_i (1 - d_i) - y_i d_i]}{V(d_i)} \\ &= \frac{E[y_i d_i] - E[d_i]E[y_i]}{V(d_i)} = \frac{\text{Cov}(y_i, d_i)}{V(d_i)}\end{aligned}$$

Nævneren er givet på tilsvarende vis $\frac{\text{Cov}(x_i, d_i)}{V(d_i)}$ og således har vi

$$\tilde{\beta}_1 = \frac{\text{Cov}(y_i, d_i)}{\text{Cov}(x_i, d_i)} = \beta_1 + \frac{\text{Cov}(u_i, d_i)}{\text{Cov}(x_i, d_i)} = \beta_1 + \frac{E[u_i d_i] - E[u_i]E[d_i]}{\text{Cov}(x_i, d_i)} = \beta_1$$

Paneldata og PS10



Paneldata vs. tværsnit og tidsrækker

Paneldata: samme enheder observeres på flere tidspunkter.

$$y_{it} = \beta_0 + \beta_1 x_{it} + u_{it}, \quad i = 1, \dots, N, \quad t = 1, \dots, T$$

- ▶ **Tværsnit:** mange enheder, ét tidspunkt.
- ▶ **Tidsrække:** én enhed, mange tidspunkter.
- ▶ **Paneldata:** mange enheder, flere tidspunkter.

I PS10: 634 personer observeret i 1997 og 2002 ($T = 2$).

Hvorfor er paneldata nyttigt?

Vi kan håndtere uobserverede, tidsinvariante forskelle mellem personer.

$$u_{it} = a_i + e_{it}$$

- ▶ a_i : fast person-specifik heterogenitet.
- ▶ Fx helbred, arbejdsmoral, præferencer for fritid.
- ▶ e_{it} : tidsvarierende stød.

Problem: Hvis $\text{Cov}(x_{it}, a_i) \neq 0$, er pooled OLS inkonsistent.

- ▶ **Pooled OLS**: ignorerer panelstrukturen.
- ▶ **First Difference**: trækker periode 1 fra periode 2.

$$\Delta y_i = \beta_1 \Delta x_i + \Delta e_i$$

- ▶ **Fixed Effects**: bruger afvigelser fra individets gennemsnit.

$$y_{it} - \bar{y}_i = \beta_1 (x_{it} - \bar{x}_i) + (e_{it} - \bar{e}_i)$$

- ▶ **Random Effects**: GLS, men kræver $\text{Cov}(x_{it}, a_i) = 0$.

Når $T = 2$: FD og FE giver samme hældningsestimater.

Hvad ryger ud i FD og FE?

Tidsinvariante variable forsvinder.

- ▶ Køn, fødselsår og fast uddannelse ændrer sig ikke over tid.
- ▶ Derfor er $\Delta x_j = 0$ i FD.
- ▶ I FE er $x_{it} - \bar{x}_i = 0$ for tidsinvariante variable.

Konsekvens: Vi kan ikke estimere deres direkte effekt.

Men: interaktioner med tidsvarierende variable kan stadig identificeres.

Hvornår bruger vi hvad?

- ▶ **POLS**: kun attraktiv hvis a_i kan antages ukorreleret med x_{it} .
- ▶ **FD/FE**: standardvalg når uobserverede faste forskelle kan være korreleret med x_{it} .
- ▶ **RE**: mere efficient end FE, men kun under stærkere antagelse.

$$\text{RE kræver: } \text{Cov}(x_{it}, a_i) = 0$$

I PS10 estimerer vi alle fire og sammenligner.

Den planlagte pensionsalder



Spørgsmål: Hvad påvirker den planlagte pensionsalder?

- ▶ Helbred
- ▶ Uddannelse
- ▶ Civilstand
- ▶ Offentlig pension og kapitalpension
- ▶ Køn og kønsforskelle i pensionsrespons

Data: Ældredatabasen, fødselskohorte 1945.

Data og model

- ▶ 634 personer.
- ▶ Observeret i 1997 og 2002.
- ▶ Balanceret panel: $634 \cdot 2 = 1268$ observationer.
- ▶ Alle er i beskæftigelse i perioden.

Pointen med paneldata er, at vi kan sammenligne personer med sig selv over tid.

$$\begin{aligned} tbalder_{it} = & \beta_0 + \beta_1 enlig_{it} + \beta_2 helbred_{it} + \beta_3 dudd1_{it} + \beta_4 dudd2_{it} \\ & + \beta_5 erfar_{it} + \beta_6 pension_{it} + \beta_7 kpenbelob_{it} + \beta_8 d2002_t \\ & + \beta_9 kvinde_i + \beta_{10}(pension_{it} \times kvinde_i) + u_{it} \end{aligned}$$

$$u_{it} = a_i + e_{it}$$

a_i kan fx være stabilt helbred, præferencer eller arbejdsevne.

Interaktionen betyder, at pensionseffekten kan være forskellig for mænd og kvinder.

$$\text{Mænd: } \frac{\partial t_{\text{balder}}}{\partial \text{pension}} = \beta_6$$

$$\text{Kvinder: } \frac{\partial t_{\text{balder}}}{\partial \text{pension}} = \beta_6 + \beta_{10}$$

Test for samme effekt:

$$H_0 : \beta_{10} = 0$$

Gruppespørgsmål



Kan modellen estimeres konsistent med pooled OLS?

Diskutér især:

- ▶ Hvad kræves om a_i ?
- ▶ Hvad kræves om e_{it} ?
- ▶ Er det realistisk at $\text{Cov}(x_{it}, a_i) = 0$?

Nøgleidé: POLS virker kun, hvis de uobserverede faste forskelle ikke er korreleret med regressorerne.

Pooled OLS kræver samlet eksogenitet:

$$E[u_{it} | X_i] = 0$$

Da $u_{it} = a_i + e_{it}$, kræver det bl.a.:

$$E[a_i | X_i] = 0, \quad E[e_{it} | X_i] = 0$$

Typisk bekymring: planlagt pensionsalder, helbred, pension og uddannelse kan alle være relateret til faste persontræk.

Hvad sker der ved first differencing?

$$\Delta y_i = \beta_1 \Delta x_i + \Delta e_i$$

- ▶ a_i fjernes automatisk.
- ▶ Tidsinvariante variable kan ikke estimeres.
- ▶ Konsistens kræver stadig eksogenitet af ændringerne.

Nøglekrav: Δx_i må ikke være korreleret med Δe_i .

Svaridé til gruppespørgsmål 2

FD løser problemet med a_j :

$$\Delta u_i = (a_i - a_i) + (e_{i2} - e_{i1}) = \Delta e_i$$

Men FD kræver stadig:

$$E[\Delta e_i \mid \Delta X_i] = 0$$

Intuition: Ændringer i fx helbred eller pension må ikke være drevet af samtidige uobserverede ændringer i pensionsplaner.

STATA øvelser

Før panelkommandoer skal STATA kende individ- og tidsvariablen.

```
1 xtset id year
```

Typisk output fortæller:

- ▶ panel-id
- ▶ tidsvariabel
- ▶ om panelet er balanceret

STATA: pooled OLS, FD og FE

Pooled OLS estimeres som almindelig OLS.

```
1 reg tbalder enlig helbred dudd1 dudd2 erfar pension ///  
2   kpenbelob d2002 kvinde c.pension#i.kvinde
```

FD:

```
1 reg d.tbalder d.enlig d.helbred d.pension
```

FE

```
1 xtreg tbalder enlig helbred pension kpenbelob d2002, fe
```

Husk: Tidsinvariante variable, fx **kvinde**, kan ikke estimeres med FD/FE.

`\end{undervisning}`
